

# The Art of Forecasting

---

Gianluca Campanella

7<sup>th</sup> June 2018

# Hello!

My name is **Gianluca** [dʒanˈluːka]

# What I do nowadays

I'm a Data Scientist at



**Microsoft**

**in Algorithms and Data Science**

## What I do nowadays

I also run my own company





Estimand.com

that provides

**Data Science training and mentoring**

[https://github.com/gcampanella/  
ndr-2018](https://github.com/gcampanella/ndr-2018)

# References



# Contents

---

Motivation

Modelling

Results and recommendations

# What's a time series?

Any data that change **over time**

- Typically continuous (including counts)
- Time gives natural ordering



# What's forecasting?

## Regression

- Value of  $y$  given values for the predictors  $X$
- Does not depend on time (or temporal effect is negligible)

# What's forecasting?

## Regression

- Value of  $y$  given values for the predictors  $X$
- Does not depend on time (or temporal effect is negligible)

## Forecasting


- Value of  $y$  given **previous values** of  $y$
- Some models can also incorporate exogenous predictors

Can we forecast in changing environments?


Predictability depends on...

- Availability of data
- Our understanding of contributing factors
- Whether our forecasts affect the process we're trying to forecast

# A word of caution




# A word of caution



What happened?

# A word of caution





# Motivation

---

[AVVENIRE](#) [CEI NEWS](#) [SIR](#) [TV2000](#) [RADIO INBLU](#) [FISC](#)

Questo sito usa cookie di terze parti (anche di profilazione) e cookie tecnici. Continuando a navigare accetti i cookie. [Cambia policy](#)

accetta

[SEZIONI](#) [RUBRICHE](#) [CEI](#) [PAPA](#) [OPINIONI](#) [SINODO GIOVANI](#)

[Home](#) - [Opinioni](#) [Editoriali](#) | [Il direttore risponde](#) | [Le nostre voci](#)

## Dati come di guerra nell'Italia 2015. Attenti ai morti

Gian Carlo Bianchiardi venerdì 11 dicembre 2015

Leggendo i dati forniti dall'Istat sul totale dei morti in Italia nei primi sette mesi del 2015 - ultimo aggiornamento a tutt'oggi disponibile - si scopre un aumento di 39mila decessi rispetto agli stessi primi sette mesi del 2014. La cosa non è affatto marginale se si pensa che ciò corrisponde a un aumento dell'11% e che, se confermato su base annua, porterebbe a 664mila morti nel 2015 contro i 598mila dello scorso anno. Si tratterebbe di un aumento di ben 66mila unità, che si annuncia in gran parte concentrato sulla componente femminile (+40mila) e che verosimilmente coinvolgerà soprattutto la componente più anziana della popolazione residente nel nostro Paese. Il dato è impressionante. Ma ciò che lo rende del tutto anomalo è il fatto che per trovare un'analogia impennata della mortalità, con ordini di grandezza comparabili, si deve tornare indietro sino al 1943 e, prima ancora, occorre risalire agli anni tra il 1915 e il 1918: due periodi bellici della nostra storia che largamente spiegano dinamiche di questo tipo. Viceversa, in un'epoca come quella attuale, in condizioni di pace e con uno stato di benessere che, nonostante tutto, è da ritenersi ancora ampio e generalizzato, come si giustifica un rialzo della mortalità di queste dimensioni? È solo la naturale conseguenza del cambiamento in un popolo che diventa sempre più anziano o è (anche) un segnale di allarme rispetto a un sistema socio-sanitario che, dopo averci abituati al continuo allungamento della vita, - con guadagni sensibili anche in

pubblicità

**OPINIONI**

**Secondo noi** Gettner il «re delle gaffe» che alimenta anche l'euroscetticismo



Se il principe Filippo è il noto gaffeur della Casa reale britannica, il tedesco Guenther Gettner è il suo «il titolare di bilancio e risorse umane nell'azienda».



Looking up token.rubiconproject.com...

Se questo sito, utilizzando cookie tecnici e, previo tuo consenso, cookie di profilazione, analisi e di terze parti, per migliorare i servizi e la tua esperienza, non sei d'accordo con le sue preferenze, hai vari strumenti di più a prendere il consenso solo sui cookie tecnici. Cliccando su "Sì" accetti tutti i cookie. Cliccando su "No" rifiuti tutti i cookie. Cliccando su "Gestisci" accetti solo i cookie tecnici. Cliccando su "Gestisci" accetti solo i cookie di profilazione. Cliccando su "Gestisci" accetti solo i cookie di terze parti. Cliccando su "Gestisci" accetti tutti i cookie.

NETWORK **L'Espresso** **LE MONDIE** LAVORO ANNUNCI ASTE **Accedi**

**Rai** **Cronaca**


Home Politica Economia Sport Spettacoli Tecnologia Motori Tutte le sezioni **D** **Rep**

## Mortalità, impennata misteriosa nel 2015: "Quei 45mila scomparsi come in una guerra"

*L'Istat: decessi aumentati dell'11,3%, ai livelli degli anni Quaranta. E gli esperti si interrogano: ci ammaliamo di più o ci curiamo peggio?*

di MICHELE BOCCI

Lo legge dopo 23 dicembre 2015



**ROMA** - Come durante la guerra, ma senza la guerra. Come se vivessimo sotto i bombardamenti. Uno studio interroga e preoccupa esperti in mezza Italia: nel 2015 il numero di morti nel nostro Paese è salito dell'11,3%. In un anno significherebbe 67mila decessi in più rispetto al 2014 (ad agosto sono già 45mila), per un incremento che davvero non si vedeva da decenni. I dati del bilancio demografico mensile dell'Istat raccontano qualcosa di attono, che già impegna i demografi e presto, quando saranno note le fasce di età e le cause, darà molto da lavorare anche agli esperti della sanità. Le schede appena pubblicate sul sito dell'Istituto di statistica arrivano fino all'agosto scorso e dicono che nei primi otto mesi sono stati registrati 445mila decessi, contro i 399mila nello stesso periodo dell'anno precedente. Si è

**IPU LIETI** **IPU CONDIVI**

**la Repubblica**  
**tvzap** **tv** **social TV** Segui su **f**

**STAGIONE IN TV**

**1** 20:30 - 21:30 **Sole igneo - Il Ritorno**

**2** 21:00 - 23:00 **Scanzonissima**

**3** 21:25 - 23:05 **Blood Father**

**4** 20:25 - 21:25 **CSI Miami - Stagione 7 - Ep. 19**

[Guida Tv completa >](#)

**IL MOUNDO** **ESBOOK**

**TOP ESBOOK**  
**La mia vita da Giapponese**  
di Virginia Camarillo

**LIBRO E ESBOOK**  
**La macchina fotografica**  
di Marco Carbone

Questo sito utilizza cookie, anche di terze parti, per inviarti pubblicità e servizi in linea con le tue preferenze. Se vuoi saperne di più o negare il consenso a tutti o ad alcuni cookie [clicca qui](#). Chiudendo questo banner, accettando questa pagina o cliccando su qualsiasi elemento accetti l'uso dei cookie.

ATTUALITÀ PARLAMENTO POLITICA POLITICA ECONOMICA DOSSIER BLOG

4  Governo, le crisi più lunghe con l'impegnata dello spread si risapò l'ipotesi di Governo politico

4  Sale lo spread: ecco quali sono gli effetti per le imprese e l'economia reale

4  Spread, perché sale e perché ci deve interessare

4  Belgio, chi è l'alleato di giorno?

**DIETRO I DATI ISTAT**

## In Italia nel 2015 sono morte 54mila persone in più (+9%). Ecco le possibili cause

—di Enrico Marro 25 febbraio 2016



**I**l rapporto Istat sugli indicatori demografici 2015 ha confermato le stime dei mesi scorsi: in Italia l'anno scorso i decessi hanno toccato quota 653mila, 54mila in più del 2014 (+9,1%). Con un tasso di mortalità, pari al 10,7 per mille, che è risultato il più alto dal secondo dopoguerra in poi. L'aumento di mortalità è concentrato tra gli anziani (75-95 anni). Come è stato possibile?

**Invecchiamento popolazione e "posticipo dei decessi"**

L'Istat spiega come, dal punto di vista demografico, il picco di mortalità del 2015 sia in parte dovuto a effetti strutturali connessi all'invecchiamento e in parte al posticipo delle morti non avvenute nel biennio 2013-2014. «Il picco di mortalità del 2015 porta con sé

**VIDEO**



30 maggio 2016  
Quali effetti per i risparmiatori italiani e per le banche di casa nostra dell'impegnata dello spread? Lo spiega Maria Longo

**I PIÙ LETTI DI ITALIA**

- 1. COTTARELLI AL COLLE DEI «CONTRIO INFORMALE»** 28 maggio 2016  
Risparmio e spread di un governo M5S-Lega, Salvini o Giannetti in pole per Palazzo Chigi. Milano apre
- 2. CRISI ISTITUZIONALE** 30 maggio 2016  
Cottarelli «C'è spaccio di Governo politico, resto in attesa». Salvini: no, ma non a luglio»
- 3. DIETRO LA SVOLTA DI DI NARDI** 30 maggio 2016  
M5S di lotta «vittoria» di governo: pena la paura di perdere il voto moderato
- 4. NOME** 25 settembre 2017  
Bernardo Mattarella nuovo ad della Banca del Mezzogiorno
- 5. LO STALLO POLITICO** 28 maggio 2016  
Dall'impegnata dello spread alle gioiellerie sul governo, comincia di una giornata di servizio

# Motivation

<http://demo.istat.it/>



<https://github.com/gcampanella/istat-demographics>

**Geo**  
**mo**  
ital.it  
A cura di

**L'ISTAT**

**Istat**  
English

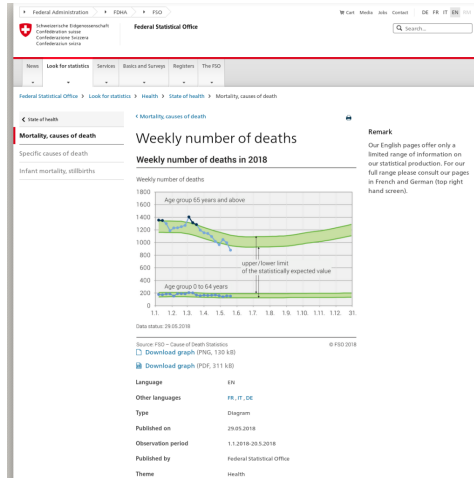
## popolazione residente

<b>Popolazione Residente</b> per età, sesso e stato civile al 31° dicembre
Anno 2016
Anno 2015
Anno 2014
Anno 2013
Anno 2012
Anno 2011

## bilancio demografico

<b>Bilancio Demografico</b> e popolazione residente per sesso al 31 dicembre
Anno 2016
Anno 2015
Anno 2014
Anno 2013
Anno 2012
Anno 2011
Anno 2010
Anno 2009
Anno 2008
Anno 2007
Anno 2006
Anno 2005
Anno 2004
Anno 2003
Anno 2002
Anno 2001
Anno 2000
Anno 1999
Anno 1998
Anno 1997
Anno 1996
Anno 1995
Anno 1994
Anno 1993
Anno 1992
Anno 1991
Anno 1990
Anno 1989
Anno 1988
Anno 1987
Anno 1986
Anno 1985
Anno 1984
Anno 1983
Anno 1982
Anno 1981
Anno 1980
Anno 1979
Anno 1978
Anno 1977
Anno 1976
Anno 1975
Anno 1974
Anno 1973
Anno 1972
Anno 1971
Anno 1970
Anno 1969
Anno 1968
Anno 1967
Anno 1966
Anno 1965
Anno 1964
Anno 1963
Anno 1962
Anno 1961
Anno 1960
Anno 1959
Anno 1958
Anno 1957
Anno 1956
Anno 1955
Anno 1954
Anno 1953
Anno 1952
Anno 1951
Anno 1950
Anno 1949
Anno 1948
Anno 1947
Anno 1946
Anno 1945
Anno 1944
Anno 1943
Anno 1942
Anno 1941
Anno 1940
Anno 1939
Anno 1938
Anno 1937
Anno 1936
Anno 1935
Anno 1934
Anno 1933
Anno 1932
Anno 1931
Anno 1930
Anno 1929
Anno 1928
Anno 1927
Anno 1926
Anno 1925
Anno 1924
Anno 1923
Anno 1922
Anno 1921
Anno 1920
Anno 1919
Anno 1918
Anno 1917
Anno 1916
Anno 1915
Anno 1914
Anno 1913
Anno 1912
Anno 1911
Anno 1910
Anno 1909
Anno 1908
Anno 1907
Anno 1906
Anno 1905
Anno 1904
Anno 1903
Anno 1902
Anno 1901
Anno 1900
Anno 1899
Anno 1898
Anno 1897
Anno 1896
Anno 1895
Anno 1894
Anno 1893
Anno 1892
Anno 1891
Anno 1890
Anno 1889
Anno 1888
Anno 1887
Anno 1886
Anno 1885
Anno 1884
Anno 1883
Anno 1882
Anno 1881
Anno 1880
Anno 1879
Anno 1878
Anno 1877
Anno 1876
Anno 1875
Anno 1874
Anno 1873
Anno 1872
Anno 1871
Anno 1870
Anno 1869
Anno 1868
Anno 1867
Anno 1866
Anno 1865
Anno 1864
Anno 1863
Anno 1862
Anno 1861
Anno 1860
Anno 1859
Anno 1858
Anno 1857
Anno 1856
Anno 1855
Anno 1854
Anno 1853
Anno 1852
Anno 1851
Anno 1850
Anno 1849
Anno 1848
Anno 1847
Anno 1846
Anno 1845
Anno 1844
Anno 1843
Anno 1842
Anno 1841
Anno 1840
Anno 1839
Anno 1838
Anno 1837
Anno 1836
Anno 1835
Anno 1834
Anno 1833
Anno 1832
Anno 1831
Anno 1830
Anno 1829
Anno 1828
Anno 1827
Anno 1826
Anno 1825
Anno 1824
Anno 1823
Anno 1822
Anno 1821
Anno 1820
Anno 1819
Anno 1818
Anno 1817
Anno 1816
Anno 1815
Anno 1814
Anno 1813
Anno 1812
Anno 1811
Anno 1810
Anno 1809
Anno 1808
Anno 1807
Anno 1806
Anno 1805
Anno 1804
Anno 1803
Anno 1802
Anno 1801
Anno 1800

# Motivation



## Original data

- Births, deaths, and net migration
- Monthly resolution from January 2004 till November 2017
- At municipality (*comune*) level
- Stratified by sex

## Aggregated data



- Deaths only
- Monthly resolution from January 2004 till November 2017
- At **region** level ( $N = 20$ )
- Stratified by sex



Data are **unnormalised** monthly counts

- Boundary changes
- Population size (pre-census vs post-census)
- Calendar adjustment

# Exploratory data analysis



# Analysis

Family	Method	Package
Baseline	Naïve (RW)	forecast
	Seasonal naïve	forecast
	Naïve with drift	forecast
	Average	forecast
Univariate	ETS	forecast
	ARIMA	forecast
	BSTS	bsts
	Prophet	prophet
Hierarchical	HTS	hts

# Modelling

---

# Naïve and average methods

For all  $h = 1, 2, \dots$ ,

---

**Naïve (RW)**

$$\hat{y}_{T+h|T} = y_T$$

**Seasonal naïve with period  $m$**

$$\hat{y}_{T+h|T} = y_{T+h-m(\lfloor (h-1)/m \rfloor + 1)}$$

**Naïve with drift**

$$\hat{y}_{T+h|T} = y_T + h(y_T - y_1)/(T - 1)$$

**Average**

$$\hat{y}_{T+h|T} = \sum_{t=1}^T y_t / T$$

---

# Modelling

---

## Exponential smoothing

# Simple exponential smoothing (SES)

Given a smoothing parameter  $0 \leq \alpha \leq 1$ ,

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha) \hat{y}_{t|t-1}$$

$$\hat{y}_{t+h|t} = \ell_t \quad \text{(forecast)}$$

$$\ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1} \quad \text{(smoothing)}$$

# Holt's linear trend method

Given a smoothing parameter  $0 \leq \beta \leq 1$ ,

$$\hat{y}_{t+h|t} = \ell_t + hb_t \quad \text{(forecast)}$$

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}) \quad \text{(level)}$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1} \quad \text{(trend)}$$



# Gardner and McKenzie's damped trend method

Given a damping parameter  $0 < \phi < 1$ ,

$$\hat{y}_{t+h|t} = \ell_t + (\phi + \phi^2 + \dots + \phi^h)b_t \quad \text{(forecast)}$$

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1}) \quad \text{(level)}$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)\phi b_{t-1} \quad \text{(trend)}$$

# Holt-Winters' seasonal (additive) method

Given a smoothing parameter  $0 \leq \gamma \leq 1$  and a frequency  $m \in \mathbb{N}$ ,

$$\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(\lfloor (h-1)/m \rfloor + 1)} \quad (\text{forecast})$$

$$\ell_t = \alpha(y_t - s_{t-m} + (1 - \alpha)(\ell_{t-1} + b_{t-1})) \quad (\text{level})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1} \quad (\text{trend})$$

$$s_t = \gamma(y_t - \ell_t) + (1 - \gamma)s_{t-m} \quad (\text{seasonality})$$

# ETS methods

- **Error**

- Additive
- Multiplicative

- **Trend**

- None
- Additive
- Additive damped



$2 \times 3 \times 3 = 18$   
possible configurations

- **Seasonality**

- None
- Additive
- Multiplicative

# Modelling

---

## ARIMA models

# Backshift operator $\mathcal{B}$

Let's introduce the **backshift operator**  $\mathcal{B}$ ,

$$\mathcal{B}y_t = y_{t-1}$$

$$\mathcal{B}^2 y_t = y_{t-2}$$

$$\vdots$$

$$\mathcal{B}^m y_t = y_{t-m}$$

## Backshift operator $\mathcal{B}$

We can rewrite first-order differences in terms of  $\mathcal{B}$ ,

$$\begin{aligned}y_t - y_{t-1} &= y_t - \mathcal{B}y_t \\ &= (1 - \mathcal{B})y_t\end{aligned}$$

In general,  $\mathcal{B}$  follows algebraic rules,

$$\begin{aligned}(1 - \mathcal{B})(1 - \mathcal{B}^m)y_t &= (1 - \mathcal{B}^m - \mathcal{B} + \mathcal{B}^{m+1})y_t \\ &= y_t - y_{t-m} - y_{t-1} + y_{t-m-1} \\ &= (y_t - y_{t-m}) - (y_{t-1} - y_{(t-1)-m})\end{aligned}$$

# Autoregressive and moving average models

**Autoregressive  $AR(p)$  model of order  $p$**

$$y_t = \beta_0 + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + \epsilon_t$$

**Moving average  $MA(q)$  model of order  $q$**

$$y_t = \gamma_0 + \gamma_1 \epsilon_{t-1} + \dots + \gamma_q \epsilon_{t-q} + \epsilon_t$$

## Non-seasonal ARIMA( $p, d, q$ ) model

$$(1 - \beta_1 \mathcal{B} - \dots - \beta_p \mathcal{B}^p)(1 - \mathcal{B})^d y_t = \alpha + (1 + \gamma_1 \mathcal{B} + \dots + \gamma_q \mathcal{B}^q) \epsilon_t$$



## Non-seasonal ARIMA( $p, d, q$ ) model

$$(1 - \beta_1 \mathcal{B} - \dots - \beta_p \mathcal{B}^p)(1 - \mathcal{B})^d y_t = \alpha + (1 + \gamma_1 \mathcal{B} + \dots + \gamma_q \mathcal{B}^q) \epsilon_t$$

## Seasonal ARIMA( $p, d, q$ )( $P, D, Q$ ) $_m$ model

$$\begin{aligned} (1 - \beta_1 \mathcal{B} - \dots - \beta_p \mathcal{B}^p) & (1 - \mathbf{B}_1 \mathcal{B}^m - \dots - \mathbf{B}_p \mathcal{B}^{pm})(1 - \mathcal{B})^d (1 - \mathcal{B}^D) y_t \\ & = \alpha + (1 + \gamma_1 \mathcal{B} + \dots + \gamma_q \mathcal{B}^q) (1 + \Gamma_1 \mathcal{B}^m + \dots + \Gamma_Q \mathcal{B}^{Qm}) \epsilon_t \end{aligned}$$

# Modelling

---

## Other methods

# Bayesian Structural Time Series (BSTS) models

- Introduced by S. L. Scott and H. Varian (Google)
- Ensemble method
- Structural time series model + regression component

## Model evaluated

- Local linear trend
- Seasonal model with  $m = 12$

# Prophet

- Introduced by S. J. Taylor and B. Letham (Facebook)
- Curve fitting (similarly to GAMs)
- Decomposition into trend, seasonality, and holidays

## Model evaluated

- Default settings
- No daily or weekly seasonality

# Hierarchical time series models

- Introduced by R. J. Hyndman et al. (Monash University)
- Independent forecasts + aggregation at different levels
- Many different aggregation methods

## Models evaluated

- Forecasting methods: ARIMA, ETS, RW
- 5 aggregation methods  $\times$  4 weighting schemes

# Modelling

---

## Measures

# Scale-dependent measures

Given the prediction errors  $e_{T+h} = y_{T+h} - \hat{y}_{T+h}$ , ...

---

Measure	
Mean absolute error	$\text{mean}( e_t )$
Root-mean-square error	$\sqrt{\text{mean}(e_t^2)}$

---

# Percentage errors

Given the **percentage** errors  $p_t = 100e_t/y_t$ , ...

---

Measure	
Mean absolute percentage error	$\text{mean}( p_t )$
Symmetric MAPE	$\text{mean}(200 y_t - \hat{y}_t /(y_t + \hat{y}_t))$

---



# Scaled errors

Given the **scaled** errors...

$$q_t = \frac{e_t}{\frac{1}{T-1} \sum_{t'=2}^T |y_{t'} - y_{t'-1}|} \quad \text{or} \quad q_t = \frac{e_t}{\frac{1}{T-m} \sum_{t'=m+1}^T |y_{t'} - y_{t'-m}|},$$

the **mean absolute scaled error** is simply  $\text{mean}(|q_t|)$


## Interpretation

For  $q_t < 1$ , the forecast is better than the average (seasonal) naïve forecast (computed on the training data)


# Results and recommendations

---


# Seasonal naïve forecasts




# ETS forecasts





# Univariate models




# Univariate models



# HTS models



# HTS models





## And the winner is...

Method	MAPE
BSTS	6.52%
Prophet	6.58%
ETS	6.62%
HTS (bottom-up ETS)	6.62%
ARIMA	7.49%
Seasonal naïve	9.44%
Average	9.83%
Naïve (RW)	11.4%
Naïve with drift	11.8%

## Time series are messy!

- Temporal resolution and spacing
- Calendar adjustment
- Model evaluation and cross-validation
- Hierarchical structure

## Time series are fun!

- Data visualisation
- Models (often) interpretable
- Anomaly detection

# Future work

- Compare even more models (including neural networks)
- Include exogenous covariates such as temperature
- Build a user interface